



Universidad Autónoma De Nuevo León
Facultad de Ciencias Físico Matemáticas.



Datos del docente:

Maestro: Jose Anastacio Saldaña Hernandez.

Materia: Minería de datos.

Practica 4: Comprobar diferencias entre grupos.

Datos del estudiante:

Nombre: Adrián Alejandro Briseño Gonzalez.

Matricula: 2073871.

Grupo: 031.

San Nicolas de los Garza Garcia, Nuevo Leon.

Introducción

En esta práctica se comprobará si hay diferencia en datos etiquetados. Primeramente, se debe realizar un análisis de normalidad para determinar si el subconjunto de datos elegido sigue una distribución normal. Posteriormente, se comprueba si existen o no diferencias entre las varianzas de los grupos estudiados. Las anteriores acciones se hacen con el fin de verificar los supuestos de ANOVA y en base a los resultados tomar la decisión de hacer el análisis mediante un ANOVA o elegir una prueba de Kruskal-Wallis.

El objeto de estudio para esta practica es, ¿existe una diferencia significativa en el promedio de tiros a puerta de equipos locales según el resultado final de cada partido?

La parte fundamental para este análisis se concentra en analizar para determinar si existe o no una distribución normal en los datos (así como también en los residuos) para saber si se cumplen o no los supuestos de ANOVA.

Subconjunto objetivo.

El subconjunto de datos de objeto de estudio es el siguiente que contiene 2 columnas: tiros a puerta en cada partido de los equipos locales y resultado final.

	home_shots_on_target	full_time_result
0	2	A
1	4	A
2	11	H
3	4	D
4	8	D
...	...	...
6075	7	D
6076	7	H
6077	8	H
6078	6	H
6079	8	H

Métricas de grupos descriptivas.

Aquí se muestran métricas descriptivas, las mas relevantes son:

- Count: Indica la cantidad de partidos que hay para cada resultado.
- Mean: Indica el promedio de tiros a puertas por locales por partido de acuerdo al resultado final.
- Std: Es la dispersión de los tiros a puerta por locales con respecto al promedio de tiros a puerta en partidos de acuerdo al resultado final.
- Min/max: Indican las cantidades mínimas y máximas de tiros a puertas de locales en cada categoría de resultado final.

	count	mean	std	min	25%	50%	75%	max
full_time_result								
A	1731.0	3.660312	2.146413	0.0	2.0	3.0	5.0	14.0
D	1552.0	4.056701	2.169927	0.0	2.0	4.0	5.0	13.0
H	2797.0	5.763318	2.616479	0.0	4.0	5.0	7.0	18.0

Residuos de los datos.

Cada residuo es el resultado de la diferencia entre el promedio de tiros a puerta y los tiros a puerta de cada partido.


```
Residuos de los datos.  
0      -1.660312  
1       0.339688  
2       5.236682  
3      -0.056701  
4       3.943299  
...  
6075    2.943299  
6076    1.236682  
6077    2.236682  
6078    0.236682  
6079    2.236682  
Length: 6080, dtype: float64
```

Comprobar supuestos de ANOVA.


Los supuestos de ANOVA en los que se decidió investigar fueron el de la normalidad de los residuos y homogeneidad de varianzas, porque lo principal es determinar si los datos siguen o no una distribución normal.

Análisis de la normalidad de los residuos.

La siguiente grafica es un Q&Q en el cual se observa la tendencia que siguen los residuos en comparativa a la distribución normal, se puede observar que los residuos no siguen la línea recta y es probable que no sean normales.



A continuación, en el histograma se puede observar que existen picos, colas y asimetría, lo cual es muy diferente a la campana de la distribución normal y por lo tanto, hay mas evidencia de que los residuos no siguen la distribución normal.



Test Shapiro-Wills para analizar si los datos provienen de la distribución normal.

Anteriormente se analizo si los residuos eran normales o no, ahora se emplea la prueba de Shapiro-Wills como recurso para determinar si los datos del subconjunto son normales o no. Debo aclarar aquí que el valor mas relevante es el valor p, ya que esta prueba es sensible si la muestra es de tamaño muy grande, de hecho, en la salida del algoritmo se muestra la advertencia de usarla en muestras grandes.

Output del test Shapiro-Wills

El nivel de significancia utilizado fue de 0.05

```
C:\Users\Adrian Briseno\AppData\Local\Programs\Python\Python314\Lib\site-packages\scipy\stats\_axis_nan_policy.py:601:
rate. Current N is 6080.
    res = hypotest_fun_out(*samples, **kws)
Prueba de Shapiro-Wills

Estadístico W: 0.9633904463004804

P-Valor: 1.1643867540676048e-36

Se rechaza H0: Existe ev. estadística para decir que los datos NO provienen de una distr. normal.
```

Como la muestra es grande, la métrica de mayor enfoque es el valor P, ya que determina si la desviación que se observo es significativa para el resultado de la prueba. El valor W se encarga de medir que tan cercano están los datos de la normalidad, en este caso no se toma mucho en cuenta por el tamaño de la muestra ya que, si se toma como base para dar un resultado, entonces, en este caso se puede caer en un falso positivo.

Como en este caso el valor P es muy pequeño (1.164×10^{-36} aproximadamente) indica que los datos son poco compatibles con la hipótesis nula de que los datos provienen de una distribución normal.

Como el valor de P es menor al nivel de significancia, entonces se rechaza la hipótesis nula que indica que los datos provienen de una distribución normal. Por lo tanto, los datos NO provienen de una distribución normal.

Prueba de Levene para estudiar el supuesto de varianzas iguales en los grupos de datos etiquetados.

En esta prueba se determina si las varianzas de los grupos son iguales.

Grupos:

- H: Partidos que gana el local.
- D: Empates.
- A: Partidos que gana el visitante.

Output de la prueba de Levene.

```
Prueba de Levene

Estadístico W: 41.65691697471318

P-Valor: 1.0752822981967248e-18

Se rechaza H0: Las varianzas NO son iguales.
```

El estadístico de Levene obtenido fue de 41.6570 aproximadamente, este valor indica que hay evidencia contra la igualdad de varianzas. Como el valor p (1.076×10^{-18} aproximadamente) es menor al nivel de significancia, indica que los datos son poco compatibles con la hipótesis nula que indica que las varianzas de los 3 grupos son iguales. Por lo tanto se rechaza la hipótesis nula, las varianzas NO son iguales.

Conclusiones acerca de los supuestos de ANOVA.

Dado a las métricas y graficas obtenidas anteriormente, se tiene evidencia estadística que indica que los datos no siguen una distribución normal y las varianzas de los 3 grupos no son iguales, por lo tanto se descarta analizar los datos a través de la prueba ANOVA.

Elección de la prueba de Kruskal-Wallis para analizar comprobar diferencias en datos etiquetados.

Se selecciono la prueba de Kruskal-Wallis ya que es una prueba no paramétrica adecuada para datos no normales, como no se cumplieron los supuestos de ANOVA, entonces se trabajo con la prueba de Kruskal-Wallis.

Output de la prueba de Kruskal Wallis.

```
Prueba de Kruskal-Wallis  
Estadístico W: 872.1938834980334  
P-Valor: 4.0318523874844227e-190  
Se rechaza H0: Existe ev. estadística para decir que al menos un grupo es diferente de los demas.
```

El valor del estadístico de la prueba es de 872.1939 que indica que existe una gran diferencia entre los rangos de los grupos.

Se puede observar que el valor de P es muy pequeño y es menor al nivel de significancia, entonces se rechaza la hipótesis nula de que los 3 grupos son iguales. Por lo tanto, se puede decir que al menos un grupo es diferente.

Conclusiones

- Se comprobó mediante grafico Q-Q, histograma que los residuos no son normales.
- También se probó mediante la prueba de Levene que las varianzas de los 3 grupos (H, A y D) son diferentes y esto significa que hay dispersión significativa de los tiros a puerta de los locales en cada categoría de resultado final de partido.
- La prueba de Shapiro-Wills indico que los datos no provienen de una distribución normal.
- Los datos no son normales y las varianzas de los 3 grupos no son iguales, por lo tanto, no cumplen los supuestos de ANOVA.
- **La prueba de Kruskal-Wallis determino que existe evidencia estadística de que no todos los grupos se comportan de la misma manera respecto a los tiros a puerta del equipo local.**