

Universidad Autónoma De Nuevo León

Facultad de Ciencias Físico Matemáticas



Datos del docente:

Maestro: Jose Anastacio Saldaña Hernandez.

Materia: Mineria de datos.

Practica 6: Clasificacion de datos a traves de un modelo de clasificacion que utiliza el algoritmo K-Vecinos Mas Cercanos (KNN)

Datos del estudiante:

Nombre: Adrián Alejandro Briseño Gonzalez.

Matricula: 2073871.

Grupo: 031.

San Nicolas de los Garza Garcia, Nuevo Leon.

Introducción

En este trabajo se trabajará con el algoritmo K Vecinos mas cercanos con el objetivo de investigar primeramente como análisis exploratorio, la correlación de variables estadísticas que miden el rendimiento de los equipos para saber cuales son las variables que más se correlacionan entre sí.

El objetivo principal de investigación en este trabajo es saber, ¿en qué medida las estadísticas de rendimiento de los equipos permiten clasificarlos en niveles alto, medio y bajo mediante el algoritmo KNN?

La idea central será clasificar el nivel de rendimiento de los equipos en “alto”, “medio” y “bajo” de acuerdo con la posición en la que quedaron al final de las temporadas.

Datos, descripción y preparación del conjunto de datos

Transformación del conjunto de datos.

Al principio en el dataset original, se tienen registros que es la información de partidos desde el inicio de la temporada 2011, hasta el termino de la temporada 2026. Se hizo una simulación para obtener la tabla final de posiciones de cada temporada, posteriormente, todos esos registros se juntaron para crear un nuevo conjunto de datos de estudio.

A continuación, se muestran algunas tablas de temporada finales (no son todas):

Temporada 2011-2012

```
===== Temporada 2011-2012 =====
 Posicion      Equipo  PJ  G  E  P  GF  GC  DG  PUNTOS nivel_rendimiento
        1 Real Madrid  38 32  4  2 121  32  89     100              alto
        2   Barcelona  38 28  7  3 114  29  85      91              alto
        3    Valencia  38 17 10 11  59  44  15      61              alto
        4      Malaga  38 17  7 14  54  53   1      58              alto
        5  Ath Madrid  38 15 11 12  53  46   7      56              alto
        6     Levante  38 16  7 15  54  50   4      55             medio
        7     Osasuna  38 13 15 10  44  61 -17      54             medio
        8    Mallorca  38 14 10 14  42  46  -4      52             medio
        9     Sevilla  38 13 11 14  48  47   1      50             medio
       10  Ath Bilbao  38 12 13 13  49  52  -3      49             medio
       11    Sociedad  38 12 11 15  46  52  -6      47             medio
       12       Betis  38 13  8 17  47  56  -9      47             medio
       13      Getafe  38 12 11 15  40  51 -11      47             medio
       14     Espanol  38 12 10 16  46  56 -10      46              bajo
       15   Vallecano  38 13  4 21  53  73 -20      43              bajo
       16    Zaragoza  38 12  7 19  36  61 -25      43              bajo
       17     Granada  38 12  6 20  35  56 -21      42              bajo
       18  Villarreal  38  9 14 15  39  53 -14      41              bajo
       19    Sp Gijon  38 10  7 21  42  69 -27      37              bajo
       20   Santander  38  4 15 19  28  63 -35      27              bajo
```

Temporada 2015-2016

```
===== Temporada 2015-2016 =====
 Posicion      Equipo  PJ  G  E  P  GF  GC  DG  PUNTOS nivel_rendimiento
        1   Barcelona  38 29  4  5 112  29  83      91              alto
        2 Real Madrid  38 28  6  4 110  34  76      90              alto
        3  Ath Madrid  38 28  4  6  63  18  45      88              alto
        4  Villarreal  38 18 10 10  44  35   9      64              alto
        5  Ath Bilbao  38 18  8 12  58  45  13      62              alto
        6       Celta  38 17  9 12  51  59  -8      60             medio
        7     Sevilla  38 14 10 14  51  50   1      52             medio
        8      Malaga  38 12 12 14  38  35   3      48             medio
        9    Sociedad  38 13  9 16  45  48  -3      48             medio
       10       Betis  38 11 12 15  34  52 -18      45             medio
       11    Valencia  38 11 11 16  46  48  -2      44             medio
       12  Las Palmas  38 12  8 18  45  53  -8      44             medio
       13       Eibar  38 11 10 17  49  61 -12      43             medio
       14     Espanol  38 12  7 19  40  74 -34      43              bajo
       15   La Coruna  38  8 18 12  45  61 -16      42              bajo
       16    Sp Gijon  38 10  9 19  40  62 -22      39              bajo
       17     Granada  38 10  9 19  46  69 -23      39              bajo
       18   Vallecano  38  9 11 18  52  73 -21      38              bajo
       19      Getafe  38  9  9 20  37  67 -30      36              bajo
       20     Levante  38  8  8 22  37  70 -33      32              bajo
```

Temporada 2025-2026



```
===== Temporada 2025-2026 =====
 Posicion      Equipo  PJ  G  E  P  GF  GC  DG  PUNTOS nivel_rendimiento
        1   Barcelona  38 31  1  6  95  36  59      94              alto
        2 Real Madrid  38 27  5  6  77  35  42      86              alto
        3  Villarreal  38 22  6 10  72  46  26      72              alto
        4  Ath Madrid  38 21  6 11  62  44  18      69              alto
        5       Betis  38 15 15  8  59  48  11      60              alto
        6       Celta  38 14 12 12  53  48   5      54             medio
        7      Getafe  38 15  6 17  32  38  -6      51             medio
        8   Vallecano  38 12 14 12  41  44  -3      50             medio
        9    Valencia  38 13 10 15  46  55  -9      49             medio
       10    Sociedad  38 11 13 14  59  61  -2      46             medio
       11     Espanol  38 12 10 16  43  55 -12      46             medio
       12  Ath Bilbao  38 13  6 19  43  58 -15      45             medio
       13       Elche  38 10 13 15  49  57  -8      43             medio
       14      Alaves  38 11 10 17  44  56 -12      43              bajo
       15     Sevilla  38 12  7 19  46  60 -14      43              bajo
       16     Osasuna  38 11  9 18  44  50  -6      42              bajo
       17    Mallorca  38 11  9 18  47  57 -10      42              bajo
       18     Levante  38 11  9 18  47  61 -14      42              bajo
       19      Girona  38  9 14 15  39  55 -16      41              bajo
       20      Oviedo  38  6 11 21  26  60 -34      29              bajo
```

Elección de los niveles de rendimiento y características.

En las anteriores imágenes, se observa el nivel de rendimiento de cada equipo a lo largo de cada temporada, ¿en base a que se desarrollo este criterio y como se clasifica cada equipo?

Clasificar los equipos por su nivel de rendimiento en “alto”, “medio” y “bajo” se eligió en base en la posición final que quedan en la tabla, a continuación, se explica mas a detalle.

Posicion final del equipo	Nivel de rendimiento
[1-5]	**Alto:** Son los equipos que quedan primeros y alcanzan puestos para jugar competiciones europeas como Champions League y Europa League.
[6-13]	**Medio**: Son los equipos que quedan en el rango de posiciones [6-13].
[14-20]	**Bajo:** Son los equipos que quedan en el rango de posiciones [14-20] que son las últimas posiciones (de la posición 18 a la 20, son los puestos de descenso).

Características elegidas

Las características elegidas para esta investigación se muestran a continuación y se menciona que significa cada una.

Características	Significado
GF	Goles anotados a favor para un equipo.
GC	Goles anotados en contra para un equipo.
DG	Es la diferencia entre los goles favor y los goles en contra.
G	Son los partidos ganados en la temporada.
E	Son los partidos empatados en la temporada.
P	Son los partidos perdidos en la temporada.

Se seleccionaron estas variables como características de estudio porque si no se tiene la posición del equipo, ver a través el rendimiento de estas características es posible principalmente con los goles a favor, diferencia de goles y que tipo de partidos tiene mas (empatados, ganados o perdidos).

Lo anterior se justifica con las siguientes métricas:

- El coeficiente de correlación entre DG (Diferencia de goles) y G (partidos ganados) esta entre (0.92-0.96) durante las temporadas, lo que indica que mientras un equipo siga ganando partidos, la diferencia de goles seguirá yendo en forma positiva.
- Los goles a favor (GF) se relacionan de manera fuerte y positiva en los partidos ganados. El coeficiente de correlación varía entre (0.80-0.93) entre las diferentes temporadas.

Características excluidas y justificación.

- **PJ:** Son los partidos jugados por cada equipo a lo largo de una temporada, es una constante con valor 38.
- **Puntos y posición:** Estas variables están directamente relacionadas con la clasificación final utilizada para definir las categorías (recordando que el criterio de nivel de rendimiento es en base a la posición final que quedan), esto representa indirectamente el nivel de rendimiento.
- **Equipo:** Representa el nombre del equipo y no es una característica numérica para calcular distancias directamente para el algoritmo KNN.

Implementación del algoritmo KNN

Estandarización de características.

La estandarización de características se utiliza aquí porque KNN utiliza distancias, por lo que una característica con valores grandes podría influir mas que otra si no se escalan adecuadamente. El escalador se ajusta con los datos de entrenamiento y después se aplica a los datos de prueba.

A continuación, se describen los pasos seguidos para implementar el algoritmo de la práctica con el algoritmo KNN.

1. Separación de las características y la variable objetivo.
2. División de los datos en entrenamiento y prueba, se utiliza un 20% para prueba y lo demás para entrenamiento.
3. Las clases “alto”, “medio” y “bajo” son codificadas como números porque al final se genera un grafico de regiones de decisión para poder interpretar las clases. En este paso los datos de la variable objetivo de entrenamiento son estudiados y transformados, una vez hecho lo anterior se transforman los datos de prueba de la variable objetivo.
4. Estandarizar las características: Al momento de transformar los datos con el escalador, dentro de fit_transform el modelo aprende la media y desviación estándar de cada característica, posteriormente la "normaliza" para que el promedio sea 0 y su desviacion sea de 1. Posteriormente, con transform el escalador transforma los datos de prueba con lo aprendido anteriormente en fit_transform.
5. Aplicar reducción de la dimensionalidad: Como se tiene un conjunto de 6 características, no es posible mostrar así en un gráfico 2 dimensiones los datos. En este paso se emplea la técnica PCA para reducir la dimensionalidad de las caracteristicas a 2 dimensiones. Es decir, la idea de este proceso es transformar los datos de 6 dimensiones a 2 dimensiones buscando contener la mayor informacion posible de las caracteristicas con el objetivo de poder visualizar una proyección en un gráfico de 2 dimensiones.
6. Posteriormente, se obtienen las características de entrenamiento y de prueba reducidas a 2 dimensiones (es un vector de 2 dimensiones).
7. Esta parte es iterativa porque se itera sobre unos valores para el hiperparametro k. En cada iteración, se crea, entrena y se obtienen las predicciones para un modelo que trabaja con el algoritmo KNN. Posteriormente, se genera un reporte de métricas para observar el rendimiento del modelo con datos que no vio.

Experimentación y resultados

Elección de los valores para el hiperparametro K.

El valor k, indica la cantidad de vecinos que tomara en cuenta el algoritmo KNN. Si se trabaja con clasificación, se clasifica el punto de acuerdo con la clase más popular en el vecindario. Si se trabaja con regresión, se calcula un promedio sobre el vecindario.

Los valores de k utilizados para experimentar son: 3,5,7,9,11,13,15. Se seleccionaron estos valores con la intención de hacerlo a prueba y error y visualizar la comparación de rendimiento con cantidades pequeñas y grandes de vecinos.

Ejecución del programa.

A continuación, se muestra la ejecución del algoritmo KNN con los diferentes valores de K, aquí se puede visualizar el reporte de métricas obtenido y de manera grafica la ejecución del algoritmo para cada valor de k.

Para K = 3

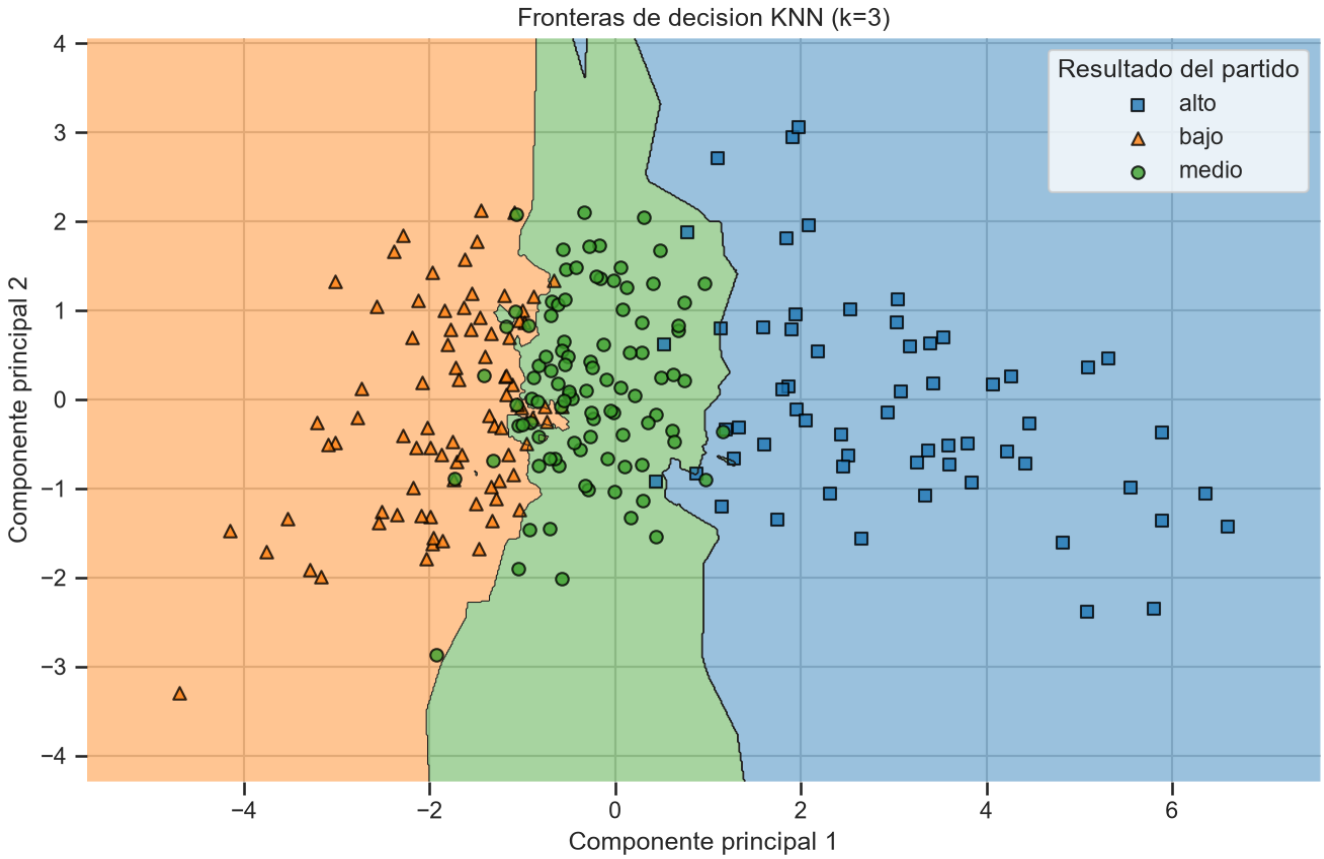
```
=====Para k = 3 =====
              precision    recall  f1-score   support

           0     0.8750    0.9333    0.9032        15
           1     0.8636    0.9048    0.8837        21
           2     0.8636    0.7917    0.8261        24

    accuracy                         0.8667        60
   macro avg     0.8674    0.8766    0.8710        60
weighted avg     0.8665    0.8667    0.8655        60


Matriz de confusion
    0   1   2
0  14   0   1
1   0  19   2
2   2   3  19

============================================================
```



Para k = 5

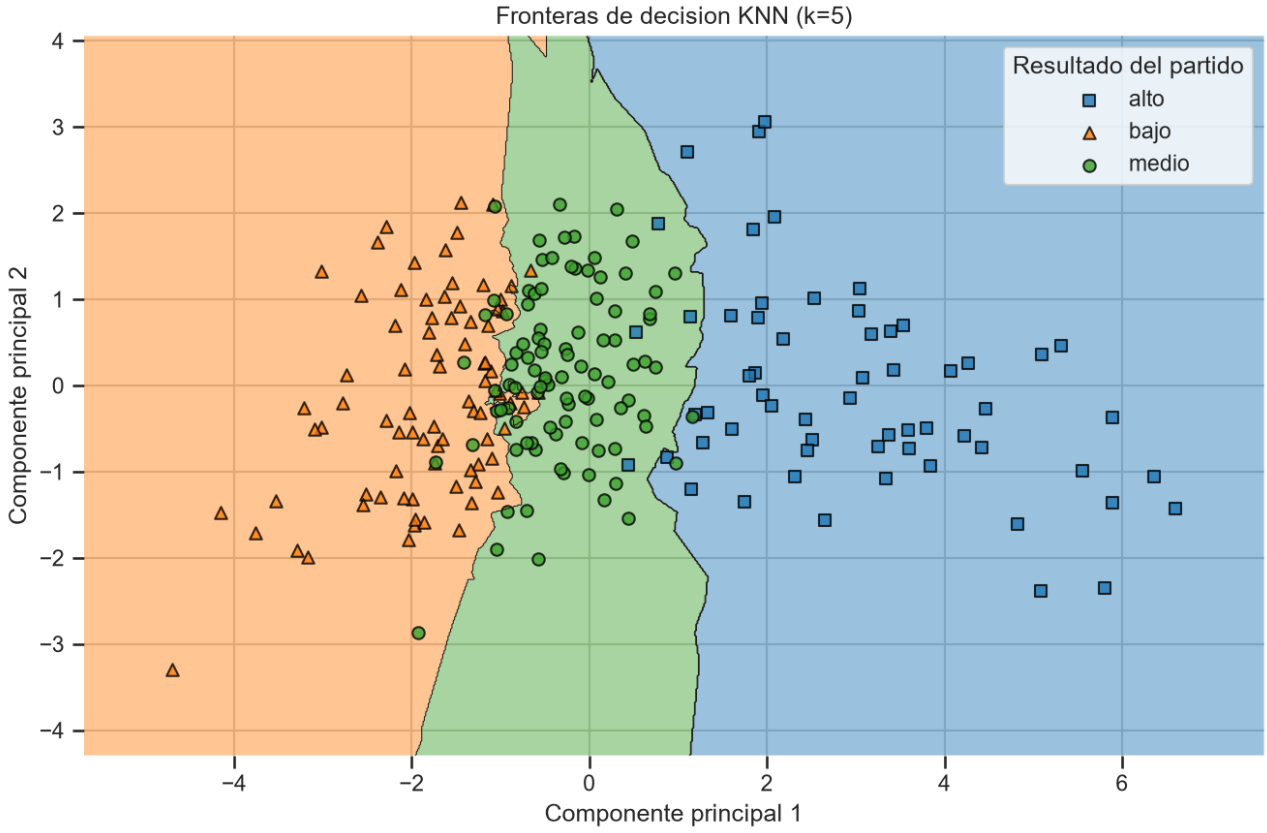
```
=====Para k = 5 =====
              precision    recall  f1-score   support

           0     0.8750    0.9333    0.9032        15
           1     0.8636    0.9048    0.8837        21
           2     0.8636    0.7917    0.8261        24

    accuracy                         0.8667        60
   macro avg     0.8674    0.8766    0.8710        60
weighted avg     0.8665    0.8667    0.8655        60


Matriz de confusion
    0   1   2
0  14   0   1
1   0  19   2
2   2   3  19

============================================================
```



Para K = 7

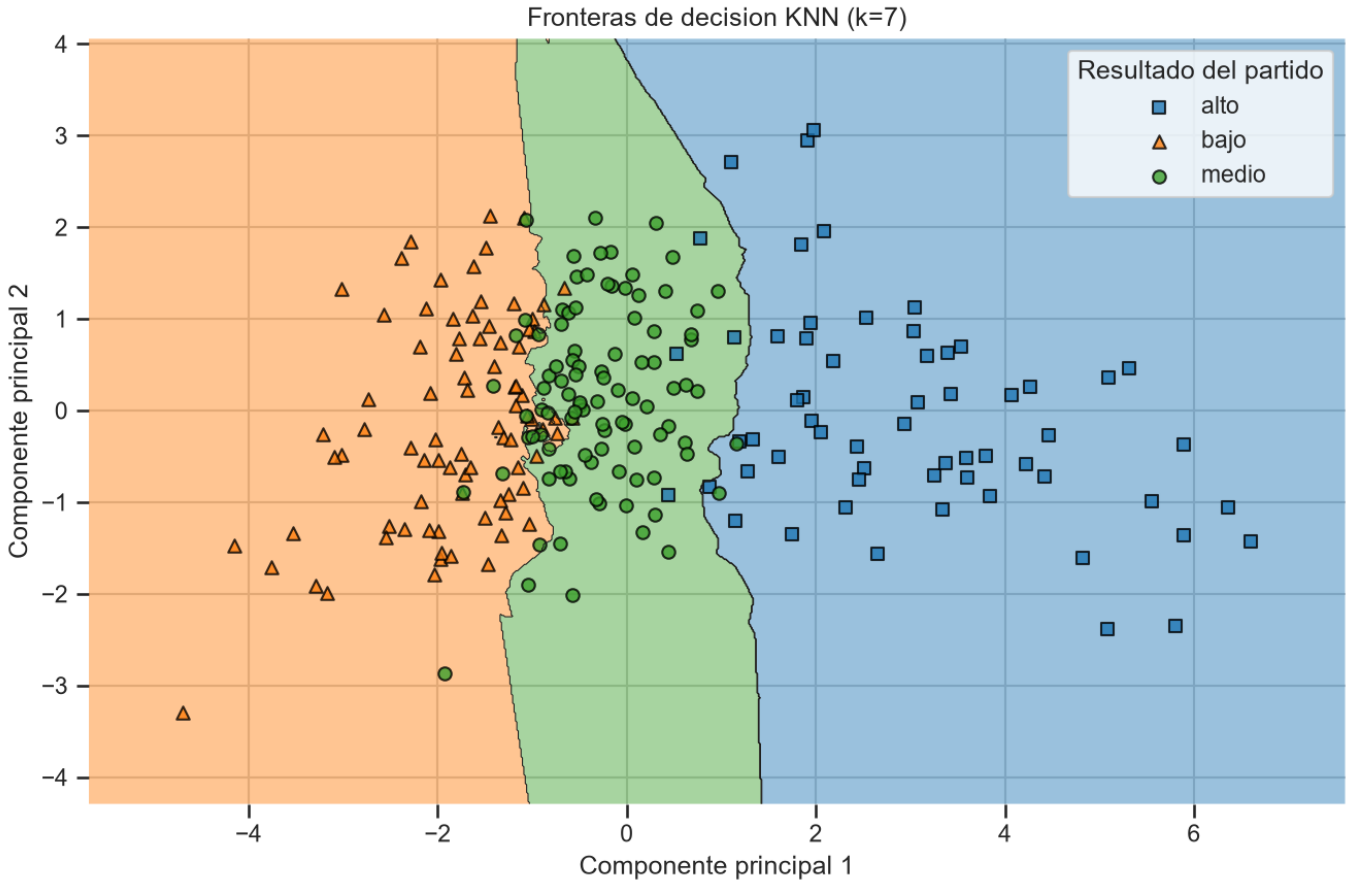
```
=====Para k = 7 =====
              precision    recall  f1-score   support

           0     0.8750    0.9333    0.9032        15
           1     0.9091    0.9524    0.9302        21
           2     0.9091    0.8333    0.8696        24

    accuracy                         0.9000        60
   macro avg     0.8977    0.9063    0.9010        60
weighted avg     0.9006    0.9000    0.8992        60


Matriz de confusion
    0   1   2
0  14   0   1
1   0  20   1
2   2   2  20

============================================================
```



Para K = 9

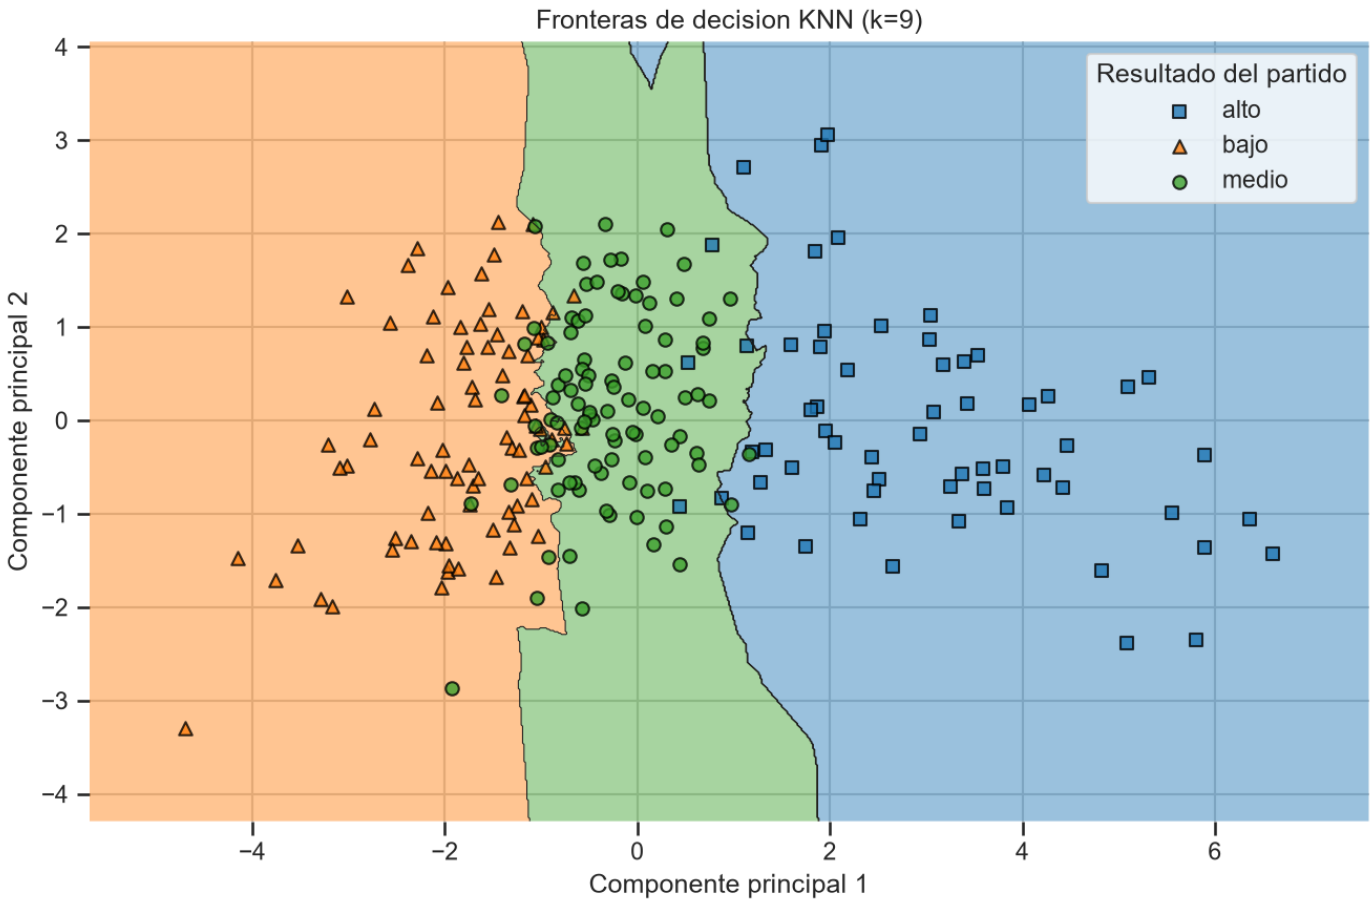
```
=====Para k = 9 =====
              precision    recall  f1-score   support

           0     0.8824    1.0000    0.9375        15
           1     0.9048    0.9048    0.9048        21
           2     0.9091    0.8333    0.8696        24

    accuracy                         0.9000        60
   macro avg     0.8987    0.9127    0.9039        60
weighted avg     0.9009    0.9000    0.8989        60


Matriz de confusion
    0   1   2
0  15   0   0
1   0  19   2
2   2   2  20

============================================================
```



Para K = 11

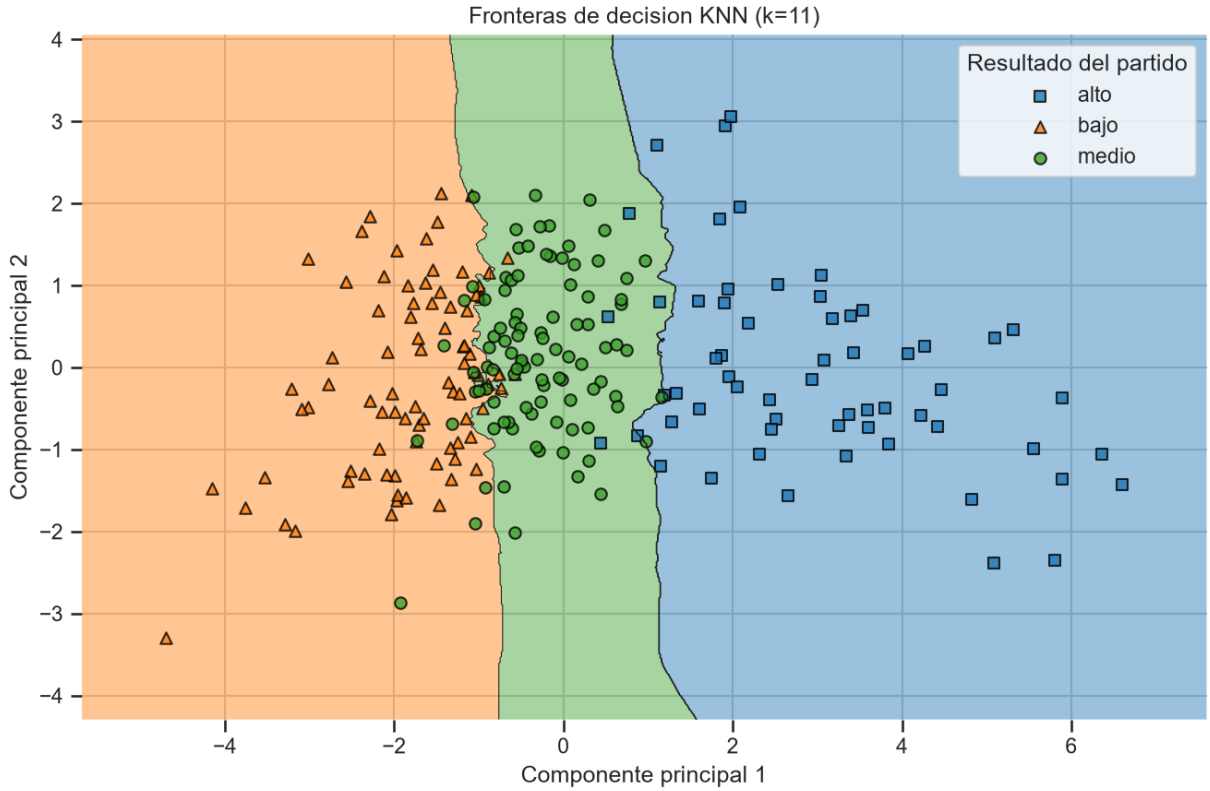
```
=====Para k = 11 =====
              precision    recall  f1-score   support

           0     0.8824    1.0000    0.9375        15
           1     0.9000    0.8571    0.8780        21
           2     0.8696    0.8333    0.8511        24

    accuracy                         0.8833        60
   macro avg     0.8840    0.8968    0.8889        60
weighted avg     0.8834    0.8833    0.8821        60


Matriz de confusion
    0   1   2
0  15   0   0
1   0  18   3
2   2   2  20

============================================================
```



Para K = 13

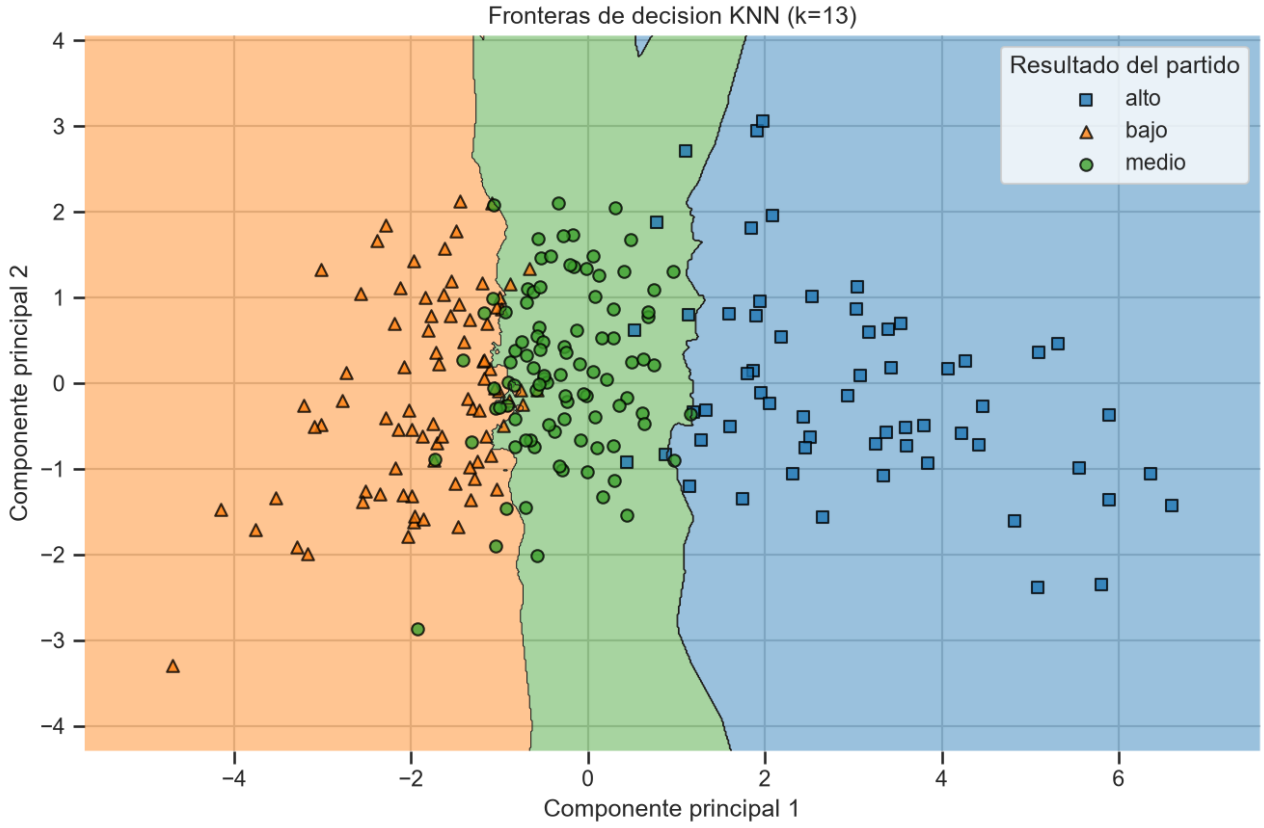
```
=====Para k = 13 =====
              precision    recall  f1-score   support

           0     0.8750    0.9333    0.9032        15
           1     0.9048    0.9048    0.9048        21
           2     0.8696    0.8333    0.8511        24

    accuracy                         0.8833        60
   macro avg     0.8831    0.8905    0.8864        60
weighted avg     0.8832    0.8833    0.8829        60


Matriz de confusion
    0   1   2
0  14   0   1
1   0  19   2
2   2   2  20

============================================================
```



Para K = 15

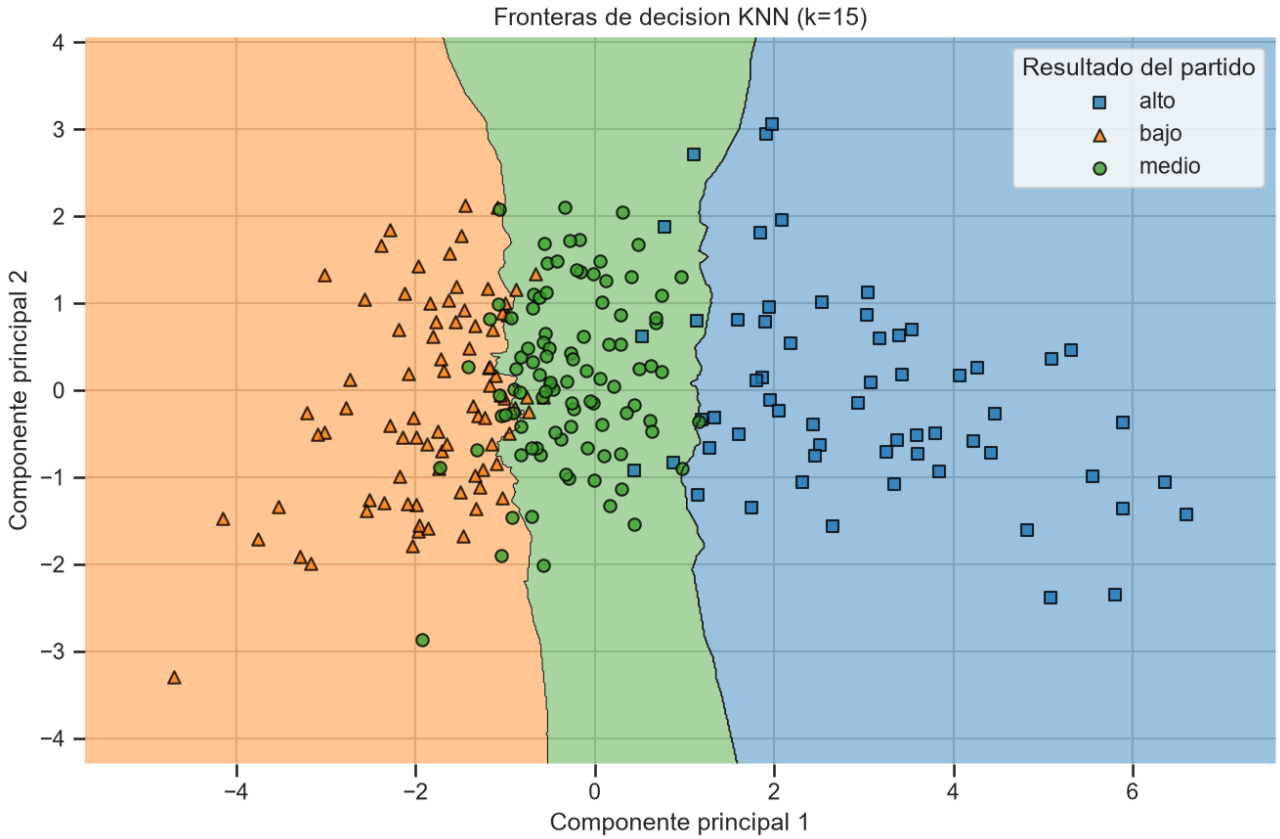
```
=====Para k = 15 =====
              precision    recall  f1-score   support

           0     0.8750    0.9333    0.9032        15
           1     0.8636    0.9048    0.8837        21
           2     0.8636    0.7917    0.8261        24

    accuracy                         0.8667        60
   macro avg     0.8674    0.8766    0.8710        60
weighted avg     0.8665    0.8667    0.8655        60


Matriz de confusion
    0   1   2
0  14   0   1
1   0  19   2
2   2   3  19

============================================================
```



Comparación de diferentes valores de K.

Valor de K	Accuracy	Precision	Recall	Observaciones
3	86.67%	86.74%	87.66%	• El modelo clasificó correctamente al **86.67 % de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **86.74 %**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al **87.66 % de los equipos que realmente pertenecían a cada clase**. • Un equipo que realmente tenía un rendimiento **alto** fue clasificado como **medio**. • Dos equipos cuyo rendimiento real era **bajo** fueron clasificados como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y tres como **bajo**.
5	86.67%	86.74%	87.66%	• El modelo clasificó correctamente al **86.67 % de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **86.74 %**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al **87.66 % de los equipos que realmente pertenecían a cada clase**. • Un equipo que realmente tenía un rendimiento **alto** fue clasificado como **medio**. • Dos equipos cuyo rendimiento real era **bajo** fueron clasificados como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y tres como **bajo**.
7	90%	89.77%	90.63%	• El modelo clasificó correctamente al 90**% de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **89.77%**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al 90.63**% de los equipos que realmente pertenecían a cada clase**. • Un equipo que realmente tenía un rendimiento **alto** fue clasificado como **medio**. • Un equipo cuyo rendimiento real era **bajo** fue clasificado como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y 2 como **bajo**.
9	90%	89.87%	91.27%	• El modelo clasificó correctamente al 90**% de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **89.87%**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al 91.27**% de los equipos que realmente pertenecían a cada clase**. • Dos equipos cuyo rendimiento real era **bajo** fue clasificado como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y 2 como **bajo**.
11	88.33%	88.40%	89.68%	• El modelo clasificó correctamente al **88.33% de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **88.40%**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al **89.68% de los equipos que realmente pertenecían a cada clase**. • Dos equipos cuyo rendimiento real era **bajo** fue clasificado como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y 2 como **bajo**.
13	88.33%	88.31%	89.05%	• El modelo clasificó correctamente al **88.33% de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **88.31%**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al **89.05% de los equipos que realmente pertenecían a cada clase**. • Un equipo que realmente tenía un rendimiento **alto** fue clasificado como **medio**. • Dos equipos cuyo rendimiento real era **bajo** fueron clasificados como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y dos como **bajo**.
15	86.67%	86.74%	87.66%	• El modelo clasificó correctamente al **86.67 % de todos los equipos**. • La precisión promedio de las tres clases fue de aproximadamente **86.74 %**, lo que indica que las predicciones del modelo fueron confiables en promedio. • El modelo logró identificar correctamente al **87.66 % de los equipos que realmente pertenecían a cada clase**.

				• Un equipo que realmente tenía un rendimiento **alto** fue clasificado como **medio**. • Dos equipos cuyo rendimiento real era **bajo** fueron clasificados como **medio**. • De los equipos que realmente tenían un rendimiento **medio**, dos fueron clasificados como **alto** y tres como **bajo**.

Observaciones generales:

- La exactitud (Accuracy) fluctúa al recorrer los valores de K, alcanza una proporción máxima de 90% con los valores 7,9 para K.
- La precisión fluctúa al recorrer los valores de K, los picos de la proporción de la precisión son de 89.77% y 89.97%, para luego caer a 86.74% en K = 15 como K=3.
- Hay valores de K que ofrecen resultados muy parecidos, a continuación, se muestran agrupados:
    - 3, 5, 15.
    - 9, 11.
    - 7, 13.
- La categoría que se clasifica peor que las demás es la de nivel medio porque el modelo suele confundirse y clasifica el nivel como alto y bajo incorrectamente.
- Para esta prueba el valor de k optimo fue 9 porque tuvo menos errores al clasificar y su proporción general en cuanto a rendimiento es ligeramente mejor que de los demás valores.

Conclusiones generales y hallazgos

- En una gran medida es posible clasificar a los equipos de acuerdo con sus estadísticas de rendimiento. Esto se sustenta principalmente porque la proporción de la exactitud con la que se clasifica, varia entre 86.67% y 90%, lo cual describe que en la mayor proporción es posible clasificar a los equipos de acuerdo con sus estadísticas de rendimiento. Este hallazgo es clave porque indica que existen patrones entre equipos que pueden ser utilizados para estudios posteriores en cuanto a la competitividad y hacer comparaciones entre rendimientos.

- Al observar las métricas en las distintas iteraciones del algoritmo KNN, se pudo visualizar que existen fluctuaciones de los valores de estas. A nivel general, el modelo tiene buena generalidad y no parece haber índices de sobreajuste en los datos. Esto permite deducir que, en el experimento realizado, el modelo pudo detectar diferencias significativas para poder diferenciar cada clase y aumentar su potencia en las predicciones.

- En la matriz de confusión, se muestran pequeños errores de predicciones para las clases alto y bajo. En la clase de rendimiento “medio” es donde el modelo tiene mas dificultades para predecir, ya que suele confundirse con el nivel alto y bajo de rendimiento.

- Tras reducir la dimensionalidad de las estadísticas de rendimiento, se conserva muy buena información permitiendo explicar el 92% de la variabilidad de los datos en una proyección de 2 dimensiones.

- En los gráficos es posible ver que existe solapamiento, pero esto no indica que las clases sean indistinguibles. Esto ayuda a visualizar que pueden existir equipos con una clase de rendimiento alto, pero podría estar muy cercano a la clase de rendimiento medio, lo mismo con equipos de rendimiento bajo y equipos de nivel medio que podrían tener características de equipos de rendimiento alto o bajo.

- En el grafico de dispersión con fronteras es posible observar que, en las clases alto y bajo, existen equipos que están mas dispersos y por lo tanto alejados, esto indica que gracias a las características que tienen esos equipos, hacen muy claro el nivel de rendimiento que tienen. Mientras que, los equipos más concentrados a las fronteras de las clases indican que por sus características tienen rasgos similares a equipos con nivel de rendimiento medio.

- En la región de equipos con nivel medio se observa muy concentrada y hay equipos que se solapan. Esto es un hallazgo importante porque indica que, a lo largo de las temporadas, los equipos con nivel de rendimiento medio son más similares y sus estadísticas de rendimiento son muy parecidas. Esto se observa ligeramente para los equipos de rendimiento bajo. Para los equipos con nivel de rendimiento alto, esto no se observa y se puede inferir que el rendimiento “alto” es más variable porque históricamente los equipos con un alto rendimiento son diferente cada temporada.